

**ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**



BLM4522 PROJE TESLİM RAPORU

Proje 4: Veri Temizleme ve ETL Süreçleri Tasarımı

Mehmet Tunahan DÜZYOL

22290109

10.06.2026

Video Bağlantısı: https://youtu.be/jlBT_XegatE?si=pnksEFvOKWfrBm8u

İçindekiler

1. Giriş.....	3
1.1 Projenin Amacı.....	3
1.2 Kapsam.....	3
1.3 Kullanılan Ortam ve Araçlar.....	3
2. Kaynak Veri Analizi ve Hata Tespiti.....	4
2.1 NULL Değer Analizi.....	4
2.2 Duplicate Kayıt Analizi.....	4
2.3 Format Tutarsızlıkları.....	4
2.4 Genel Veri Kalitesi Skoru.....	4
3. ETL Mimarisi ve Veri Çıkarma (Extract).....	5
3.1 ETL Şeması Oluşturma.....	5
3.2 Staging Tablosu Tasarımı.....	5
3.3 Kaynak Verinin Staging'e Yüklenmesi.....	5
4. Veri Temizleme (Transform — Clean).....	6
4.1 NULL Renk Değerlerinin Doldurulması.....	6
4.2 Geçersiz Fiyatların İşlenmesi.....	6
4.3 Tarih Tutarsızlıklarının Tespiti.....	6
4.4 Temizleme Özeti.....	6
5. Veri Dönüştürme (Transform — Enrich).....	7
5.1 Fiyat Segmentasyonu.....	7
5.2 Ürün Adı Standardizasyonu.....	7
5.3 Dönüşüm Sonucu Analizi.....	7
6. Veri Yükleme (Load).....	8
6.1 Hedef Tablo Tasarımı.....	8
6.2 VALID Kayıtların Yüklenmesi.....	8
7. Veri Kalitesi Raporu ve Bulgular.....	9
7.1 Önce/Sonra Karşılaştırması.....	9
7.2 Segment Dağılımı.....	9
7.3 Karşılaşılan Zorluklar.....	9
7.4 Sonuç.....	9
8. Kaynakça.....	10

1. Giriş

1.1 Projenin Amacı

Bu proje, Microsoft SQL Server 2025 ortamında AdventureWorks2025 örnek veritabanı üzerinde kapsamlı bir ETL (Extract, Transform, Load) süreci tasarlamak ve uygulamak amacıyla gerçekleştirilmiştir. ETL, farklı kaynaklardan elde edilen ham verilerin temizlenerek, dönüştürülerek ve standartlaştırılarak hedef bir veritabanına yüklenmesini sağlayan temel veri mühendisliği sürecidir. Proje kapsamında üretim veritabanındaki hatalı, eksik ve tutarsız veriler tespit edilmiş; staging katmanı üzerinde sistematik temizleme ve zenginleştirme işlemleri uygulanmış; yalnızca geçerli kayıtlar hedef tabloya aktarılmıştır.

1.2 Kapsam

Proje altı ana başlık altında yapılandırılmıştır:

- Kaynak Veri Analizi: NULL değer, duplicate kayıt ve format tutarsızlıklarının tespiti
- Staging Tablosu ve Extract: ETL şeması, staging tablo tasarımı ve veri çıkarma
- Veri Temizleme (Clean): NULL doldurma, geçersiz değer işleme ve tarih doğrulama
- Veri Dönüştürme (Enrich): Fiyat segmentasyonu ve ürün adı standardizasyonu
- Veri Yükleme (Load): Geçerli kayıtların hedef tabloya aktarılması
- Kalite Raporu: Önce/sonra karşılaştırması ve segment dağılım analizi

1.3 Kullanılan Ortam ve Araçlar

Bileşen	Detay
Veritabanı Sistemi	Microsoft SQL Server 2025
Yönetim Arayüzü	SQL Server Management Studio
Kaynak Veritabanı	AdventureWorks2025
İşletim Sistemi	Windows 11

2. Kaynak Veri Analizi ve Hata Tespiti

ETL sürecinin en kritik ön adımı, kaynak verideki kalite sorunlarının sistematik olarak belirlenmesidir. Herhangi bir dönüşüm veya yükleme işlemi yapılmadan önce verinin mevcut durumunun tam olarak anlaşılması; temizleme kurallarının doğru belirlenmesini, işlenmeyecek kayıtların önceden tanımlanmasını ve sürecin sonunda ölçülmesi gereken iyileşme metriklerinin taban çizgisinin oluşturulmasını sağlar.

2.1 NULL Değer Analizi

Production.Product tablosunda yapılan NULL analizi, Color kolonunun kayıtların önemli bir bölümünde değer içermediğini ortaya koymuştur. Benzer şekilde Size ve Weight kolonlarında da yüksek oranda NULL bulunmaktadır. Bu durum, ürünlerin özellikle hammadde veya yarı mamul niteliğindeki alt kategorilerde renk, boyut ve ağırlık bilgisi olmaksızın kaydedilmesinden kaynaklanmaktadır. ListPrice kolonunda sıfır değer içeren kayıtlar tespit edilmiştir; bu kayıtlar fiyatlandırılmamış ürünleri temsil etmektedir. Person.Person tablosunda ise MiddleName ve Suffix kolonlarının büyük çoğunlukta NULL olduğu görülmüştür; bu alanlar yapısı itibarıyla opsiyonel olduğu için beklenen bir sonuçtur.

2.2 Duplicate Kayıt Analizi

Person.Person tablosunda FirstName ve LastName kombinasyonu bazında gerçekleştirilen duplicate analizi, aynı isme sahip birden fazla kaydın var olduğunu göstermiştir. Ancak bu durum bir veri hatası değildir; farklı bireyler aynı adı taşıyabilir. Asıl duplicate kontrolü birincil anahtar olan BusinessEntityID üzerinden yapılmış ve herhangi bir tekrarlı birincil anahtar tespit edilmemiştir. Bu bulgu, veritabanının referans bütünlüğü açısından sağlıklı olduğunu doğrulamaktadır.

2.3 Format Tutarsızlıkları

Person.PersonPhone tablosundaki telefon numaraları format doğrulama sorgusuna tabi tutulmuştur. Yapılan analizde harf içeren veya 7 karakterin altında kalan numara bulunmamaktadır. Bu, telefon numarası verisinin format açısından tutarlı olduğuna işaret etmektedir. Color kolonunda ise bazı kayıtlarda baş ve son boşluk karakterleri saptanmış olup bu durum TRIM işlemiyle giderilmesi gereken minimal bir format sorunudur.

2.4 Genel Veri Kalitesi Skoru

Başlangıç veri kalitesi skoru, Color, Size veya Weight kolonlarından en az birinde NULL içeren kayıtların toplam kayda oranı baz alınarak hesaplanmıştır. Bu metrik, ETL süreci öncesi taban çizgisini oluşturmakta ve işlemin tamamlanmasının ardından yeniden hesaplanarak iyileşmenin sayısal olarak ortaya konmasına imkân tanımaktadır. Analize göre kaynak tablodaki ürünlerin büyük bir bölümünde en az bir eksik alan mevcuttur.

3. ETL Mimarisi ve Veri Çıkarma (Extract)

ETL mimarisinde staging katmanı, kaynak sistem ile hedef sistem arasında tampon görevi üstlenen geçici bir veri deposudur. Kaynak tabloya hiçbir değişiklik yapılmaksızın verinin bir kopyası staging alanına alınır; tüm temizleme, dönüştürme ve doğrulama işlemleri bu katmanda gerçekleştirilir. Bu yaklaşım; kaynak sistemin bütünlüğünü korur, işlem geri alınabilirliğini sağlar ve hata ayıklama sürecini kolaylaştırır.

3.1 ETL Şeması Oluşturma

Proje kapsamında tüm ETL nesnelerini barındırmak üzere etl adında ayrı bir veritabanı şeması oluşturulmuştur. Bu şema, ETL tablolarını uygulama tablolarından mantıksal olarak izole eder ve yetkilendirme yönetimini basitleştirir. sys.schemas sistem görünümünden şema varlık kontrolü yapılarak şemanın daha önce oluşturulmuş olması durumunda tekrar oluşturma girişiminden kaçınılmıştır.

3.2 Staging Tablosu Tasarımı

etl.stg_Product tablosu, kaynak tablonun alanlarını içermekle birlikte her dönüşüm kolonunun hem ham hem temizlenmiş versiyonunu barındıran ek kolonlarla zenginleştirilmiştir. Color ve Color_Cleaned, ListPrice ve ListPrice_Cleaned çiftleri bu tasarımın somut örnekleridir. etl_status kolonu PENDING, VALID ve INVALID değerlerini alarak her kaydın işlem durumunu takip eder. etl_message kolonu INVALID kayıtlarda hata nedenini açıklar. etl_insert_date kolonu ise yüklenme zamanını kaydederek izlenebilirlik sağlar.

Kolon	Tip	Açıklama
stg_id	INT IDENTITY	Staging birincil anahtarı
ProductID	INT	Kaynak ürün ID
Color_Cleaned	NVARCHAR(15)	Temizlenmiş renk değeri
ListPrice_Cleaned	MONEY	Temizlenmiş fiyat değeri
PriceSegment	NVARCHAR(20)	ETL tarafından türetilen segment bilgisi
etl_status	NVARCHAR(20)	PENDING / VALID / INVALID
etl_message	NVARCHAR(500)	INVALID kayıtlarda hata açıklaması
etl_insert_date	DATETIME	Staging yüklenme zamanı

3.3 Kaynak Verinin Staging'e Yüklenmesi

Production.Product tablosundaki tüm kayıtlar, herhangi bir filtre uygulanmaksızın etl.stg_Product tablosuna INSERT INTO ... SELECT kalıbında aktarılmıştır. Extract adımı hiçbir dönüşüm yapılmamış; yalnızca ham veri kopyalanmıştır. Yükleme sonrasında tüm kayıtların etl_status değerinin PENDING olduğu doğrulanmıştır.

4. Veri Temizleme (Transform — Clean)

Transform adımının temizleme fazında staging tablosundaki ham veriye tanımlanmış kalite kuralları uygulanmıştır. Her kural ayrı bir UPDATE işlemi olarak gerçekleştirilmiş; böylece her adımın etkisi bağımsız olarak gözlemlenebilmiştir. Temizleme sonucunda kayıtlar VALID veya INVALID statüsüyle işaretlenmiştir.

4.1 NULL Renk Değerlerinin Doldurulması

Color_Cleaned kolonu hesaplanırken şu kurallar uygulanmıştır: Color değeri NULL ise Unspecified atanır; boş karakter dizisi ise yine Unspecified atanır; geçerli bir değer mevcutsa TRIM fonksiyonu ile baş ve son boşluklar temizlenerek Color_Cleaned alanına yazılır. Bu kural, NULL değerleri anlamlı bir varsayılan değerle doldurmakta ve hedef tabloda NOT NULL kısıtının sağlanmasını mümkün kılmaktadır.

4.2 Geçersiz Fiyatların İşlenmesi

ListPrice sıfır veya negatif olan kayıtlar için ListPrice_Cleaned NULL olarak atanmıştır. Sıfır fiyat, ürünün fiyatlandırılmamış olduğunu ifade etmekte olup bu durum bir veri bozulması değil eksikliği olarak değerlendirilmiştir. Dolayısıyla bu kayıtlar INVALID değil VALID statüsüyle işaretlenmiştir; ancak hedef tabloda fiyat bilgisi NULL olarak yer alacaktır. Bu yaklaşım, yanlışlıkla sıfır fiyatlı ürünlerin hesaplamalara dahil edilmesini önler.

4.3 Tarih Tutarsızlıklarının Tespiti

SellEndDate değerinin SellStartDate değerinden önce olduğu kayıtlar mantıksal açıdan hatalı kabul edilmiştir. Bu tür kayıtlar etl_status INVALID, etl_message ise açıklayıcı bir metin ile güncellenmektedir. Yapılan kontrolde AdventureWorks2025 veritabanında bu koşula uyan kayıt bulunmamıştır; bu durum veritabanının tarih bütünlüğü açısından sağlıklı olduğunu doğrulamaktadır.

4.4 Temizleme Özeti

Üç temizleme kuralının uygulanmasının ardından PENDING statüsündeki tüm kalan kayıtlar VALID olarak güncellenmiştir. Geçersiz tarihli kayıt bulunmadığı için INVALID kayıt sayısı sıfır olarak gerçekleşmiştir.

etl_status	Kayıt Sayısı	Açıklama
VALID	Tüm kayıtlar	Temizleme kurallarından geçti
INVALID	0	Geçersiz tarihli kayıt bulunamadı
PENDING	0	Tüm kayıtlar işlendi

5. Veri Dönüştürme (Transform — Enrich)

Transform adımının zenginleştirme fazında, temizlenmiş veriye yeni bilgiler türeterek değer kazandırılmıştır. Bu aşama, ETL sürecinin yalnızca veri hatalarını düzelten değil aynı zamanda iş zekası üretebilen bir katman olduğunu göstermektedir. Kaynak tabloda bulunmayan iki yeni bilgi ETL tarafından üretilmiştir: fiyat segmenti ve standartlaştırılmış ürün adı.

5.1 Fiyat Segmentasyonu

etl.stg_Product tablosuna PriceSegment adında yeni bir kolon eklenmiş ve her ürün ListPrice_Cleaned değerine göre bir segmente atanmıştır. Segmentasyon sınırlarının belirlenmesinde AdventureWorks2025 ürün kataloğunun fiyat dağılımı esas alınmıştır. NULL fiyatlı ürünler Tanımsız, sıfır fiyatlılar Ücretsiz, 100 TL altındakiler Ekonomik, 100—999 TL arası Orta Segment ve 1.000 TL ve üzerindeki Premium olarak sınıflandırılmıştır. Bu segmentasyon bilgisi kaynak tabloda bulunmamakta olup tamamen ETL süreci tarafından türetilmiştir.

Segment	Tanımlama	Fiyat Aralığı
Tanımsız	NULL fiyatlı ürünler	Fiyat bilgisi yok
Ücretsiz	Sıfır fiyatlı ürünler	0 TL
Ekonomik	Düşük fiyat aralığı	0 — 99 TL
Orta Segment	Orta fiyat aralığı	100 — 999 TL
Premium	Yüksek fiyat aralığı	1.000 TL ve üzeri

5.2 Ürün Adı Standardizasyonu

Ürün adları ilk harf büyük geri kalan harfler küçük şeklinde standart formata getirilmiştir. Bu işlem için UPPER(LEFT(Name, 1)) ve LOWER(SUBSTRING(Name, 2, LEN(Name))) fonksiyonları birleştirilmiştir. Standardizasyon yalnızca VALID statüsündeki kayıtlara uygulanmıştır. Farklı kaynaklardan gelen verilerde büyük/küçük harf tutarsızlığı yaygın bir kalite sorunudur; bu adım veri sunumunu tutarlı hale getirmektedir.

5.3 Dönüşüm Sonucu Analizi

Zenginleştirme aşamasının tamamlanmasının ardından segment bazında dağılım analizi yapılmıştır. Bu analiz; her segmentteki ürün sayısını, toplam içindeki yüzde payını ve ortalama, minimum ile maksimum fiyat değerlerini içermektedir. Sonuçlar hedef tabloya yüklenmeden önce iş birimi tarafından gözden geçirilmesi amacıyla raporlanmıştır.

6. Veri Yükleme (Load)

ETL sürecinin son adımı olan Load aşamasında, staging tablosunda başarıyla işlemlendirilen kayıtlar hedef tabloya aktarılmıştır. Bu adımda yalnızca VALID statüsündeki kayıtlar yüklenmiş; INVALID kayıtlar otomatik olarak dışlanmıştır. Hedef tablo tasarımı, staging tablosundan farklı olarak işlem metaverisini içermemekte ve yalnızca iş verisi barındırmaktadır.

6.1 Hedef Tablo Tasarımı

etl.clean_Product tablosu, staging tablosundaki etl_status, etl_message ve etl_insert_date gibi işlem kolonlarından arındırılmış sade bir yapıyla oluşturulmuştur. Color kolonu NOT NULL kısıtı ve DEFAULT Unspecified değeriyle tanımlanmıştır; bu sayede temizleme adımındaki NULL doldurma garantisi hedef tablo seviyesinde de pekiştirilmiştir. etl_load_date kolonu yükleme zamanını kaydederek veri tazelik takibini mümkün kılmaktadır.

6.2 VALID Kayıtların Yüklemesi

INSERT INTO ... SELECT yapısı kullanılarak staging tablosundan WHERE etl_status = 'VALID' filtresiyle yalnızca geçerli kayıtlar hedef tabloya aktarılmıştır. Ham Color ve ListPrice değerleri yerine temizlenmiş Color_Cleaned ve ListPrice_Cleaned değerleri atanmıştır. Yükleme tamamlandığında kayıt sayısı sorgulanmış ve beklenen değerle eşleştiği doğrulanmıştır.

7. Veri Kalitesi Raporu ve Bulgular

7.1 Önce/Sonra Karşılaştırması

ETL sürecinin etkisini ölçmek amacıyla kaynak tablo ile hedef tablo bir UNION ALL sorgusuyla karşılaştırılmıştır.

Metrik	Kaynak (Production.Product)	Hedef (etl.clean_Product)
NULL Color	Mevcut — yüksek oran	Sıfır — Unspecified ile dolduruldu
Sıfır ListPrice	Mevcut	NULL olarak işaretlendi
Geçersiz Tarih	Sıfır kayıt	Sıfır kayıt (değişiklik yok)
PriceSegment	Kolon yok	ETL tarafından türetildi
Toplam Kayıt	Kaynak tablo toplamı	VALID kayıt sayısına eşit

7.2 Segment Dağılımı

Yüklenen kayıtların fiyat segmenti dağılımı incelendiğinde, ürün kataloğunun Premium ve Orta Segment ürünler ağırlıklı olduğu görülmektedir. Tanımsız segment, sıfır fiyatlı kaynak ürünleri temsil etmekte olup bu ürünler hedef tabloda NULL fiyatla yer almaktadır. Bu dağılım, AdventureWorks2025 ürün kataloğunun bisiklet ve spor ekipmanı odaklı yüksek fiyat segmentine yönelik yapısını yansıtmaktadır.

7.3 Karşılaşılan Zorluklar

Proje sürecinde birkaç teknik hususa dikkat edilmiştir. TRIM fonksiyonu SQL Server 2017 ve sonrasında kullanılabilen olup SQL Server 2025 ile tam uyumlu çalıştığı doğrulanmıştır. Staging ve hedef tablo aynı etl şemasında tutulduğundan şema yönetimi ve yetkilendirme basit kalmıştır. etl_status PENDING/VALID/INVALID akışı, tüm temizleme kurallarının izlenebilir ve geri alınabilir olması açısından kritik bir tasarım kararı olmuştur. Kaynak tabloya hiçbir zaman yazma işlemi yapılmamış olup bu, ETL en iyi pratiklerinden biridir.

7.4 Sonuç

Bu proje kapsamında Microsoft SQL Server 2025 üzerinde AdventureWorks2025 veritabanı kullanılarak tam bir ETL süreci başarıyla tasarlanmış ve uygulanmıştır. Kaynak veri analiziyle başlanmış, staging katmanında Extract, Clean ve Enrich adımları gerçekleştirilmiş, ardından yalnızca geçerli kayıtlar hedef tabloya yüklenmiştir. Tüm işlem adımları etl_status mekanizması sayesinde izlenebilir ve tekrarlanabilir şekilde kurgulanmıştır. Hedef tablodaki temiz ve zenginleştirilmiş veri; raporlama, analitik ve iş zekası uygulamalarında doğrudan kullanılmaya hazır durumdadır.

8. Kaynakça

- Microsoft Docs — INSERT (Transact-SQL):
<https://learn.microsoft.com/sql/t-sql/statements/insert-transact-sql>
- Microsoft Docs — UPDATE (Transact-SQL):
<https://learn.microsoft.com/sql/t-sql/queries/update-transact-sql>
- Microsoft Docs — CREATE TABLE:
<https://learn.microsoft.com/sql/t-sql/statements/create-table-transact-sql>
- Microsoft Docs — String Functions:
<https://learn.microsoft.com/sql/t-sql/functions/string-functions-transact-sql>
- AdventureWorks Sample Database:
<https://github.com/microsoft/sql-server-samples>